

Universidad Nacional de La Plata

REGRESIÓN LINEAL

Inferencias Estadísticas
Regresión Múltiple

Matemática IV

Facultad de Informática

REPASITO DE MATE III

Intervalos de Confianza

Cuando se estima un parámetro, el mismo tiene cierto margen de error.
Un intervalo de confianza permite dar un rango de valores con cierta “certeza” de que el valor verdadero se encontrará allí.
Veremos intervalos de confianza para:

- B0 (ordenada al origen de la recta)
- B1 (Pendiente de la recta)
- Respuesta media
- Predicción de respuesta

Test de Hipótesis

El test de hipótesis es una herramienta altamente utilizada en el análisis de datos. Permite verificar una hipótesis en base a los datos obtenidos

- **IMPORTANTE:** Un test de hipótesis solo es concluyente al rechazar la hipótesis nula.
- Veremos test de hipótesis acerca de la nulidad de los parámetros B0 y B1.

LAS BASES TEÓRICAS

Antes de ir a las fórmulas, charlemos sobre los fundamentos...

- Tanto $\hat{\beta}_0$ como $\hat{\beta}_1$ son estimadores *insesgados*, es decir:

$$E(\hat{\beta}_0) = \beta_0 \qquad E(\hat{\beta}_1) = \beta_1$$

- Las varianzas de los estimadores son de la forma

$$V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}} \qquad V(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}} \right)$$

- Tanto $\hat{\beta}_0$ como $\hat{\beta}_1$ estan normalmente distribuidas con las varianzas y valores medios mencionados en los puntos anteriores.

¿Recuerdan lo que era un estimador insesgado?

INTERVALOS DE CONFIANZA

$$\left[\hat{\beta}_1 - t_{\frac{\alpha}{2},n-2}\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}\ ;\ \hat{\beta}_1 + t_{\frac{\alpha}{2},n-2}\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}\right]$$

Para B1

Se considera el siguiente pivote, el cual tiene distribución *t Student* con n-2 grados de libertad.

$$T = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

$$\left[\hat{\beta}_0 - t_{\frac{\alpha}{2},n-2}\sqrt{\sigma^2\left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}}\right)}\ ;\hat{\beta}_0 + t_{\frac{\alpha}{2},n-2}\sqrt{\sigma^2\left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}}\right)}\ \right]$$

Para B0

Se considera el siguiente pivote, el cual tiene distribución *t Student* con n-2 grados de libertad.

$$T = \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\sigma^2\left(\frac{1}{n} + \frac{\overline{x}^2}{S_{xx}}\right)}}$$

RESPUESTA MEDIA Y PREDICCIÓN

La recta de regresión lineal realiza la tarea de estimar el valor medio de la respuesta (no determinística) del valor *y* para cada *x*. Del mismo modo que B0 y B1 pueden diferir del valor real, también puede hacerlo el estimador. Por ello es que se realiza un intervalo de confianza para el estimador puntual de y.

Este intervalo representa al valor promedio que ha sido visto **hasta ahora**. ¿Qué pasa si queremos ver los posibles valores que saldrán de ahora en adelante?
Como estamos hablando de eventos a futuro, estamos hablando de variables aleatorias y pasamos a necesitar un **intervalo de predicción**, que será más amplio que la respuesta media, dado que es la diferencia entre 2 variables aleatorias.

INTERVALOS DE CONFIANZA

Para respuesta media

$$T = \frac{\hat{\beta}_0 + \hat{\beta}_1 x^* - (\beta_0 + \beta_1 x^*)}{\sqrt{\sigma^2 \left(\frac{1}{n} + \frac{(x^* - \overline{x})^2}{S_{xx}}\right)}}$$

Se considera el siguiente pivote, el cual tiene distribución *t Student* con n-2 grados de libertad.

$$\left[\hat{\beta}_0 + \hat{\beta}_1 x^* - t_{\frac{\sigma}{2},n-2}\sqrt{\sigma^2 \left(\frac{1}{n} + \frac{(x^* - \overline{x})^2}{S_{xx}}\right)} \; ; \; \hat{\beta}_0 + \hat{\beta}_1 x^* + t_{\frac{\sigma}{2},n-2}\sqrt{\sigma^2 \left(\frac{1}{n} + \frac{(x^* - \overline{x})^2}{S_{xx}}\right)}\right]$$

Para predicción

$$T = \frac{Y^* - \hat{Y}^*}{\sqrt{\sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \overline{x})^2}{S_{xx}}\right)}}$$

Se considera el siguiente pivote, el cual tiene distribución *t Student* con n-2 grados de libertad.

$$\left[\hat{Y}^* - t_{\frac{\sigma}{2},n-2}\sqrt{\sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \overline{x})^2}{S_{xx}}\right)} \; ; \hat{Y}^* + t_{\frac{\sigma}{2},n-2}\sqrt{\sigma^2 \left(1 + \frac{1}{n} + \frac{(x^* - \overline{x})^2}{S_{xx}}\right)}\right]$$

SOBRE LOS TESTS DE HIPÓTESIS

Al hablar de regresión lineal, resulta particularmente útil trabajar con tests de hipótesis sobre ambos estimadores parámetros de la recta.
Recordando: el test de hipótesis plantea 2 opciones: la hipótesis nula (H0) o la alternativa (H1). De rechazarse H0, se puede afirmar H1 en consecuencia, pues las hipótesis son complementarias. De no rechazar H0, **no es posible afirmar una o la otra. No es un test concluyente**.
Los tests se definen con un nivel de confianza (prob. de error) fija, o hallando su p-valor (probabilidad mínima para poder rechazar H0)

Las fórmulas de test de hipótesis permiten comparar el valor verdadero del estimador contra una constante a elección. Tanto para B0 como B1, es útil comparar contra la constante 0. En B0, implica que no hay un “costo base” en la respuesta; en B1, una pendiente nula implica que no hay ningún tipo de relación lineal (Ej. 10).

TEST DE HIPÓTESIS

Para B1

$$T = \frac{\hat{\beta}_1 - \beta_{10}}{\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}}$$

Si $H_1: \beta_1 \neq \beta_{10}$ se rechaza H_0 si $|T| > t_{\frac{\alpha}{2},n-2}$

Si $H_1: \beta_1 > \beta_{10}$ se rechaza H_0 si $T > t_{\alpha,n-2}$

Si $H_1: \beta_1 < \beta_{10}$ se rechaza H_0 si $T < -t_{\alpha,n-2}$

Para B0

$$T = \frac{\hat{\beta}_0 - \beta_{00}}{\sqrt{\hat{\sigma}^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}}$$

Si $H_1: \beta_0 \neq \beta_{00}$ se rechaza H_0 si $|T| > t_{\frac{\alpha}{2},n-2}$

Si $H_1: \beta_0 > \beta_{00}$ se rechaza H_0 si $T > t_{\alpha,n-2}$

Si $H_1: \beta_0 < \beta_{00}$ se rechaza H_0 si $T < -t_{\alpha,n-2}$

Si $P - valor > 0.05$ entonces no se rechaza H_0 con nivel de significancia 0.05

Si $P - valor \leq 0.05$ entonces se rechaza H_0 con nivel de significancia 0.05

Siendo ***B10*** y ***B00*** las constantes a estimar.

REGRESIÓN LINEAL MÚLTIPLE

¿Te acuerdas de la regresión lineal? ¡Volvió! ... En forma de fichas

Definición 2.1. Modelo de Regresión Lineal Múltiple

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$$

Planteamos de vuelta la función de mínimos cuadrados...

$$f(b_0, b_1, \ldots, b_k) = \sum_{i=1}^{n} [y_i - (b_0 + b_1 x_{1i} + b_2 x_{2i} + \cdots + b_k x_{ki})]^2$$

Y se realizan todas las derivadas parciales, se igualan a cero, y se vuelven a despejar las ecuaciones normales

REGRESIÓN LINEAL MÚLTIPLE

$$\underbrace{\begin{pmatrix} n & \sum x_{1i} & \sum x_{2i} & \dots & \sum x_{ki} \\ \sum x_{1i} & \sum (x_{1i})^2 & \sum x_{1i}x_{2i} & \dots & \sum x_{1i}x_{ki} \\ \sum x_{2i} & \sum x_{2i}x_{1i} & \sum (x_{2i})^2 & \dots & \sum x_{2i}x_{ki} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_{1i} & \sum x_{ki}x_{1i} & \sum x_{ki}x_{2i} & \dots & \sum (x_{ki})^2 \end{pmatrix}}_{X} \cdot \underbrace{\begin{pmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_k \end{pmatrix}}_{\beta} = \underbrace{\begin{pmatrix} \sum y_i \\ \sum x_{1i}\ y_i \\ \sum x_{2i}\ y_i \\ \vdots \\ \sum x_{ki}\ y_i \end{pmatrix}}_{Y}$$

Multiplicando por la traspuesta de x y resolviendo, nos queda:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_k x_k$$

VARIANZA EN REGRESIÓN MÚLTIPLE

La *estimación de la varianza del modelo* σ^2 está basada en la suma de residuos al cuadrado:

$$SS_r = SCE = \sum (y_i - \hat{y}_i)^2 = \sum [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_k x_k)]^2$$

Definición 2.2. Estimación de la Varianza

$$\sigma^2 = \frac{SSr}{n-k-1} = \frac{\sum (y_i - \hat{y}_i)^2}{n-k-1}$$

$$R^2 = 1 - \frac{SS_r}{STC} = 1 - \frac{SCE}{STC}$$

R2 se sigue calculando de la misma forma. No obstante, agregar muchas variables puede implicar una “sobreestimación” (corregir puntualmente las diferencias obtenidas con la muestra sin aportar una contribución real). De ahí surge:

Definición 2.3. Coeficiente de Determinación Ajustado

$$R_a^2 = 1 - (1 - R^2)\left(\frac{n-k}{n-k-1}\right)$$

Y el coeficiente de correlación múltiple:

$$r = \sqrt{R_a^2}$$

¡Ojo! Es distinto a los coeficientes de correlación lineal de cada variable (Ej. 13)



Universidad Nacional de La Plata

MUCHAS GRACIAS

¡A terminar la práctica!